

医学統計学演習：資料 10

芳賀昭弘*

1 復習

被験者全員に同じ CT 装置を使って治療前後の病変の大きさを調べた。母集団のデータは正規分布に従っているものと仮定する。治療前後の病変の大きさに違いがあるかどうかを調べるには、どのような検定が必要でしょうか？

被験者を 2 群にわけて、第 1 群は CT 装置で、第 2 群は MRI 装置で病変の大きさを調べた。それぞれの群の母集団は正規分布に従うとする。装置の違いで検知される病変の大きさが異なるかどうかを調べるには、どのような検定が必要でしょうか？

ここまでは、2 群比較のための検定を行ってきました。ですが、上の 1 つ目の例で言えば、治療前、治療直後、治療後 1 ヶ月、、、（2 つ目の例でも、例えば MRI のシーケンスプロトコルを複数用意したり、PET や超音波などを含めた場合）のように 3 群以上の標本の比較を行いたい場合があります。3 群以上の比較を行いたいときに使う統計的方法として、**分散分析 (Analysis of variance: ANOVA)** と呼ばれるものがあります^{*1}。

分散分析において有意差が出た（＝どれか 2 群の間に差が出たということ）場合、次にどの群に差が出たのかを調べたいと思うのが常です。群間の比較を調べるには**多重比較法**を使います（なお、分散分析と絡めずに最初から多重比較法だけで行うほうが良いと主張する研究者も多くいますが、この演習では両方を学んでおきたいと思います）。

分散分析や多重検定を手計算で行うのは大変でした（前期の講義でやりましたね）。しかし、コンピュータでは**たった一行で**それを計算してくれるコマンドが存在します。簡単です！一方、コンピュータで計算する際に大事なことは、**読み込むデータの書き方**になります。この演習では、**データの書き方 (エクセルによる表の作り方)**を学ぶことが実用上一番の目的となります。

2 一元配置分散分析（対応なし）

StatisticsTest.csv というデータを用意しています。まずはどういう構造になっているかエクセルで開いて確認しておきましょう（A~D はある勉強方法を示しており、数字はそのような勉強方法によるテストの結果（点数）を示しているとします）。確認したら、StatisticsTest.csv を R で読み込んでください。

* Electronic address: haga@tokushima-u.ac.jp

^{*1} 3 群以上の検定の場合でも、2 群の t 検定を 3 回行うことで同じようなことができる人がありますが、これはやってはいけません！3 群以上のグループ比較を行いたいのであれば、必ず分散分析を行ってください。理由は医学統計学の講義で説明しています。

```
> data <- read.csv("StatisticsTest.csv")
```

```
> data
```

data に格納されたら、aov 関数を使って分散分析を行います。p 値はいくらでしょう？

```
> summary(aov(data$Statistics ~ data$Instruction))
```

帰無仮説 H_0 : 4 群の母平均は等しい。

対立仮説 H_1 : 4 群の母平均は等しくない。

有意水準: 5%

p 値が _____ であるので、統計検定量は有意水準 _____ であり、帰無仮説は _____

ここでわかったことは、4 群の組み合わせのうち、少なくとも 1 つの組み合わせで差がありそうだということだけで、どの組み合わせに差があるのかまでは教えてくれいていません。そのため、次に多重比較を行う流れになります。ここでは Tukey (チューキー) の方法という多重比較法を用いてみます。

```
> TukeyHSD(aov(data$Statistics ~ data$Instruction))
```

有意水準を 5% とした場合、有意差が生じたのはどの組み合わせでしょうか？

3 一元配置分散分析 (対応あり)

SubjectAssesment.csv というデータを用意しています。同じくどういう構造になっているかエクセルで開いて確認しておきましょう (A~E の学生の代数 (Linear Algebra)、微積 (Calculus)、確率統計 (Probability and Statistics) の好感度と考えることにします)。今度も aov 関数を使って解析します。ただし、前回と違ってデータをそのまま使って解析することはできません。aov 関数を使う場合、データ構造を図 1 に示すような形式にしないといけません^{*2}。

データ形式の修正は、勿論、エクセル上で行ってもよいし R 上で行ってもよいです (データ数が少ない場合、エクセルでも十分ですが、膨大なデータを扱う場合には R や他のプログラム言語を使用しないとできない場合もあります)。今回は、エクセル上で編集してみてください。図 1 右のように修正したら、作業ディレクトリに csv 形式で保存して次を実行してください (ここでは SubjectAssesment2.csv という名前で保存したことにします)。

```
> data <- read.csv("SubjectAssesment2.csv")
```

```
> summary(aov(data$Assesment ~ data$Student + data$Subject))
```

帰無仮説 H_0 : 3 科目の学生評価は等しい。

対立仮説 H_1 : 3 科目の学生評価は等しくない。

有意水準: 5%

p 値が _____ であるので、統計検定量は有意水準 _____ であり、帰無仮説は _____

多重比較も行ってみましょう。

```
> TukeyHSD(aov(data$Assesment ~ data$Student + data$Subject))
```

^{*2} 統計解析のテクニカルな面で最も重要なことは、データをどのような形式で集めて表記しておくか、によります。卒業研究などで統計解析をする場合には、結果が出た後にどのような統計解析が必要であるかを調べておき、解析がやりやすい形式で結果をまとめておくことが肝要です。

要因(学生と科目)を分ける

通常の(やりがちな)データ集計

	A	B	C	D	E
1	Student	LinearAlgebra	Calculus	ProbabilityStatistics	
2	A	7	5	8	
3	B	8	4	6	
4	C	9	7	7	
5	D	5	1	2	
6	E	6	3	5	
7					
8					



	A	B	C	D
1	Student	Subject	Assesment	
2	A	LinearAlgebra	7	
3	B	LinearAlgebra	8	
4	C	LinearAlgebra	9	
5	D	LinearAlgebra	5	
6	E	LinearAlgebra	6	
7	A	Calculus	5	
8	B	Calculus	4	
9	C	Calculus	7	
10	D	Calculus	1	
11	E	Calculus	3	
12	A	ProbabilityStat	8	
13	B	ProbabilityStat	6	
14	C	ProbabilityStat	7	
15	D	ProbabilityStat	2	
16	E	ProbabilityStat	5	
17				

図1 データ形式の修正：データ収集の際には左図のように集めるかもしれないが、aov 関数を使いたいのであれば右のような形式で集めておくと便利。

比較したい対象だけを表示したい場合には、次のように項目名を指定することもできます。

```
> fit <- aov(Assesment ~ Student + Subject, data=data)
> TukeyHSD(fit, "Subject")
```

ところで、今のデータでは、一人の学生が3つの科目を評価しました。これがもし学生が全てばらばらの15人で評価したデータであった場合にはどうすれば良いでしょうか？その場合は、対応なしの分散分析を行います。そう思って分析してみましょう。

```
> data <- read.csv("SubjectAssesment2.csv")
> summary(aov(data$Assesment ~ data$Subject))
> TukeyHSD(aov(data$Assesment ~ data$Subject))
```

対応ありの分散分析と何が違うかわかりますか？そう、対応ありの場合、

一人の学生が3つの科目を評価することによって、個人差を評価できる

ようになり、個人のばらつきを考慮して科目をより正しく評価できるようになります。

4 二元配置分散分析（対応なし）

今度は評価の要因が2つある場合を考えます。TasteAssesment.csv を用意しています。どういう構造になっているかエクセルで開いて確認してください（これは一列目：保存状態 A, B に対し、二列目：水メーカー各社の水 (I, V, B) の三列目：美味しさを点数付けしたデータです。美味しさの要因は、保存状態とメーカーの種類の2つが考えられますね。なお、修正が必要ないように形式を整えています）。やることは同じですが、要因が複数ある場合には交互作用を加えて評価します。交互作用とは複数の要因が合わさることで生じる効果のことで、解析では（因子）：（因子）という形式で書きます。交互作用を含めて分析する場合には、* を使うこともできます。以下を実行しましょう。

```
> data <- read.csv("TasteAssesment.csv")
> summary(aov(data$Assesment ~ data$Temp + data$Maker + data$Temp : data$Maker))
```

もしくは、

```
> summary(aov(data$Assesment ~ data$Temp * data$Maker))
```

帰無仮説 H_0 : 保存方法 (Temp) によって評価は変化しない。

対立仮説 H_1 : 保存方法 (Temp) によって評価は変化する。

有意水準: 5%

p 値が _____ であるので、統計検定量は有意水準 _____ であり、帰無仮説は _____

帰無仮説 H_0 : 銘柄 (Maker) によって評価は変化しない。

対立仮説 H_1 : 銘柄 (Maker) によって評価は変化する。

有意水準: 5%

p 値が _____ であるので、統計検定量は有意水準 _____ であり、帰無仮説は _____

帰無仮説 H_0 : 保存方法と銘柄の組み合わせによって評価は変化しない。

対立仮説 H_1 : 保存方法と銘柄の組み合わせによって評価は変化する。

有意水準: 5%

p 値が _____ であるので、統計検定量は有意水準 _____ であり、帰無仮説は _____

保存状態 (Temp) に対して味の評価 (Assesment) を平均してみます。グラフにすると分かり易いので、次のような関数でプロットしてみましょう。

```
> interaction.plot(data$Maker,data$Temp,data$Assesment)
```

次に銘柄 (Maker) に対して味の評価 (Assesment) を平均してみます。

```
> interaction.plot(data$Temp,data$Maker,data$Assesment)
```

これらの図を他の人に説明してみてください。横軸と縦軸は何でしょうか？これらの図から何がわかりますか？

5 二元配置分散分析 (2 要因とも対応あり)

上と同じデータを使い、“2 要因とも対応あり”の場合に拡張してみたいと思います。“2 要因とも対応あり”とは、同じ人が保存方法や銘柄の違いをそれぞれ評価した、ということです (裏を返せば、前節の結果は、全て異なる人で保存方法や銘柄による味のデータを集めていたということです)。TasteAssesment.csv に評価者 (各 Temp × Maker の組み合わせごとに、Student という項目で A~E が 1 回ずつ現れるようにする) を加えて TasteAssesment2.csv という名前で保存してください。わからない、もしくはヒントが欲しい人は TasteAssesment2hint.csv をダウンロードしてください。分析は次のように行います。

```
> data <- read.csv("TasteAssesment2.csv")
> summary(aov(data$Assesment ~ data$Temp * data$Maker + Error(data$Student
+ data$Student:data$Temp + data$Student:data$Maker
+ data$Student:data$Temp:data$Maker)))
```

対応なしとの違いは、後半の

```
Error(data$Student + data$Student:data$Temp + data$Student:data$Maker
+ data$Student:data$Temp : data$Maker))
```

の部分です。それでは以下を埋めましょう。

帰無仮説 H_0 : 保存方法 (Temp) によって評価は変化しない。

対立仮説 H_1 : 保存方法 (Temp) によって評価は変化する。

有意水準: 5%

p 値が _____ であるので、統計検定量は有意水準 _____ であり、帰無仮説は _____

帰無仮説 H_0 : 銘柄 (Maker) によって評価は変化しない。

対立仮説 H_1 : 銘柄 (Maker) によって評価は変化する。

有意水準: 5%

p 値が _____ であるので、統計検定量は有意水準 _____ であり、帰無仮説は _____

帰無仮説 H_0 : 保存方法と銘柄の組み合わせによって評価は変化しない。

対立仮説 H_1 : 保存方法と銘柄の組み合わせによって評価は変化する。

有意水準: 5%

p 値が _____ であるので、統計検定量は有意水準 _____ であり、帰無仮説は _____

前節では、交互効果がみられませんでした。しかし今回、同じデータを使ったのですが、個人差を排除した評価になっているために有意差が出やすくなります。結果はどうだったのでしょうか？

6 二元配置分散分析（1 要因のみ対応あり）

続いて、“1 要因のみ対応あり”という状況を考えてみます。上と同じデータを使いますが、保存方法 (Temp) が B のときの評価者 (Student) を F~J に変更し、TasteAssesment3.csv という名前で保存してください（もうヒントは要らないですね？）。次を実行します。

```
> data <- read.csv("TasteAssesment3.csv")
> summary(aov(data$Assesment ~ data$Temp * data$Maker + Error(data$Student/data$Maker)))
```

Error() には、被験者差と、同じ被験者が繰り返し評価した要因に対応する誤差項を指定します。

7 演習

1. ある大学の法学部 (Law)、文学部 (Literature)、理学部 (Science)、工学部 (Technology) の4学部から8名ずつの学生を無作為抽出してそれぞれテストを行った結果が以下で示されている。学部間でテストの母平均に差があるかどうかを有意水準 5% で分散分析と多重検定を実行し、評価してください。(ヒント: まずエクセルでデータを作りましょう)。また、検定する際、一元配置なのか二元配置なのか、対応ありなのか対応なしなのか、も記述してください。

Department								
Law	75	61	68	58	66	55	65	63
Literature	62	60	66	63	55	53	59	63
Science	65	60	78	52	59	66	73	64
Technology	52	59	44	67	47	53	58	49

2. 投与量を4水準 (A,B,C,D) に分けて10名の患者に実験を行ったところ、次の表に示す結果を得た。投与した量は実験の結果に影響したと言えるでしょうか? 有意水準 5% で分散分析と多重検定を実行し、評価してください。(ヒント: こちらもエクセルでデータを作りましょう)。また、検定する際、一元配置なのか二元配置なのか、対応ありなのか対応なしなのか、も記述してください。

ID	A	B	C	D
Patient 1	33.2	33.8	39.5	38.5
Patient 2	33.4	36.7	34.8	39.4
Patient 3	30.7	38.2	29.4	38.1
Patient 4	32.1	36.4	38.6	40.8
Patient 5	28.9	33.1	40.3	33.3
Patient 6	34.1	32.1	36.2	36.9
Patient 7	32.6	37.3	37.1	36.7
Patient 8	31.8	34.6	37.7	34.6
Patient 9	35.5	28.1	33.1	37.2
Patient 10	32.3	33.5	37.9	39.1